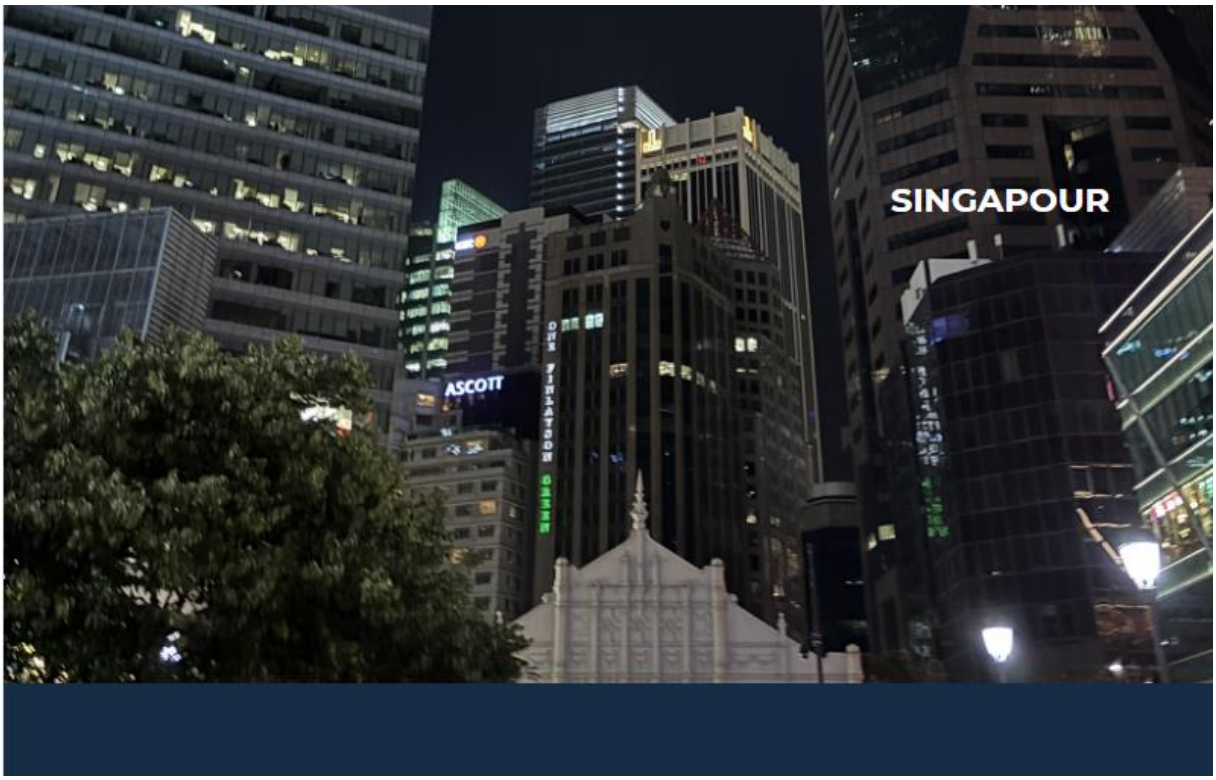
Rapport de Stage ESCO LIFESCIENCES :



Tuteur entreprise : SUSANRITO Susanrito

Tuteur universitaire : STRAUSS Olivier

Stagiaires : Teddy HARBULOT et Rendra DJUNAEDI

M1 EEA

Spécialité IRobot

2025

Remerciement

- M. LIM Lay Yew, Co-fondateur et Directeur exécutif :

  Nous tenons à exprimer toute notre gratitude à M. LIM Lay Yew pour nous avoir proposé ce stage et nous avoir permis de vivre une expérience formatrice à l'étranger. Grâce à cette opportunité, nous avons pu découvrir un nouvel environnement de travail, enrichir nos connaissances dans le domaine et nous confronter à des pratiques professionnelles

- M. SUSANRITO Susanrito, Responsable du Département Informatique :

  Nos sincères remerciements vont également à M. Susanrito pour son accompagnement constant tout au long de notre projet. Il a su nous guider avec patience et professionnalisme, en répondant à nos questions et en nous apportant un soutien technique précieux. Nous avons particulièrement apprécié la mise à disposition des équipements nécessaires ainsi que la transmission d'informations essentielles qui nous ont permis de progresser efficacement dans nos tâches.

- Mme CROITORU Madalina, Co-responsable du Master IROBOT :

  Nous remercions vivement Mme Croitoru pour son rôle dans la réalisation de ce stage. Son soutien, ses conseils avisés et ses encouragements nous ont poussés à franchir le pas d'une expérience à l'étranger, parfois intimidante au départ, mais qui s'est révélée extrêmement bénéfique. Elle a su nous transmettre des compétences pratiques et concrètes, qui complètent parfaitement notre formation théorique et qui constituent désormais des acquis solides pour la suite de notre parcours académique et professionnel.

- M. STRAUSS Olivier, Co-responsable du Master IROBOT et Tuteur :

  Nos remerciements vont également à M. Strauss pour le suivi du stage ainsi que pour les cours dispensés dans le cadre du Master, qui, bien qu'ils n'aient pas eu d'application directe durant cette expérience, représentent un apport utile pour la suite du parcours académique.

- L'équipe IT d'Esco-Lifesciences :

  Enfin, nous souhaitons remercier chaleureusement l'ensemble de l'équipe IT d'Esco-Lifesciences pour l'accueil qui nous a été réservé dès notre arrivée. Leur disponibilité, leur ouverture et leur esprit d'équipe nous ont permis de nous intégrer rapidement et de mieux comprendre le fonctionnement de l'entreprise. Au-delà de l'aspect professionnel, ils nous ont également aidés à découvrir le pays et sa culture, rendant notre séjour à la fois agréable et enrichissant. Cette expérience humaine, combinée à l'expérience technique, restera un souvenir marquant de notre parcours.

Introduction 3

Partie 1. Présentation de ESCO LIFESCIENCES 4

1. Présentation générale 4

2. Service IT 4

1. Rôle du Service 4

2. Organisation 4

Partie 2. Mission 5

3. Description 5

1. Objectifs 5

2. Enjeux 5

4. Réalisation 6

1. Phase de test sur Gmail avant intégration Outlook 6

2. Étude et comparaison de plusieurs classifieurs 7

Pourquoi avoir choisi BERT ? 7

3. Acquisition des mails sur Outlook 8

4. Préparation et traitement des données réelles 8

5. Implémentation du modèle BERT 10

6. Développement de l'interface utilisateur 10

FrontEnd : 11

BackEnd : 15

Conclusion 17

Bibliographie / Sitographie 17

Annexes 19

Introduction

Dans le cadre de notre formation en Master 1 EEA, option IRobot, à l'Université des Sciences de Montpellier, nous devions effectuer un stage de fin d'année.
Notre choix s'est porté sur l'étranger afin de réaliser une mission au sein de l'entreprise Esco Lifesciences, située à Singapour. Ce stage s'est déroulé du 1er mai au 31 juillet 2025.

Dans un contexte où les entreprises reçoivent quotidiennement des centaines de courriels, la gestion efficace de cette communication devient un enjeu crucial. Ce stage chez ESCO Lifesciences avait pour objectif de développer une solution intelligente de tri automatique des emails, en exploitant les techniques modernes de traitement du langage naturel (NLP) et les modèles pré-entraînés tels que BERT.

Ce rapport est structuré en plusieurs parties. Il commence par une présentation de l'entreprise Esco Lifesciences et du service informatique dans lequel le stage s'est déroulé. Nous décrivons ensuite la mission confiée, ses objectifs et ses enjeux, avant de détailler les différentes étapes de sa réalisation, tests préliminaires, choix des classifieurs, traitement des données, développement du modèle BERT, conception de l'interface.

La partie suivante est consacrée à l'analyse des résultats, avec une évaluation de l'atteinte des objectifs, les apports pour l'entreprise, les points forts de la solution développée, ainsi que les limites rencontrées.
Enfin, nous évoquons brièvement les activités secondaires menées durant le stage, avant de terminer par un bilan technique et personnel de cette expérience.

Partie 1. Présentation de ESCO LIFESCIENCES

1. Présentation générale

L'entreprise Esco lifesciences a été fondée à Singapour en 1978. Présente dans plus de 100 pays pour son activité dans le domaine de la fabrication d'équipements de laboratoire et de dispositifs utilisé pour de la biotechnologie, recherche médicale et dans des environnements hospitaliers. L'entreprise a pour volonté l'innovation tout en garantissant des produits conforme aux normes internationales et durable.

Effectif mondial : Plus de 1 700 employés répartis dans 54 sites, comprenant 6 centres de recherche et développement (R&D) et 6 sites de production.

Dans 3 domaines d'activité :

- Scientifique : Équipements de laboratoire pour la recherche et l'industrie.

- Médical : Dispositifs médicaux pour la fécondation in vitro (FIV).

- Healthcare : Solutions pour la production pharmaceutique et les bioprocédés.

2. Service IT

1. Rôle du Service

Ce Service compte plusieurs profils techniques afin de rentre autonome l'entreprise au niveau technologique et d'apporter de nouveau outils de développement. Il permet également d'offrir un support technique au client. Mais aussi de maintenir l'infrastructure et la cybersécurité opérationnels.

2. Organisation

Dans ce service on y retrouve donc plusieurs pôles :

- Support technique et helpdesk

- Infrastructure et cybersécurité

- Développement de logiciel

- Gestion de projets numériques et ERP

- Innovation et intégration de technologies cloud

Partie 2. Mission

3. Description

1. Objectifs

Notre mission a pour principal objectif de concevoir un programme capable de récupérer des mails depuis une boite Oulook afin de les classifier automatiquement selon leur contenu avec une interface dédiée. Permettant à l'utilisateur une consultation claire et organisée de ses mails tout en conservant les fonctionnalités essentielles d'une boite mail classique.

L'acheminement du mail et sa classification doit respecter ce système de catégories et sous catégories :

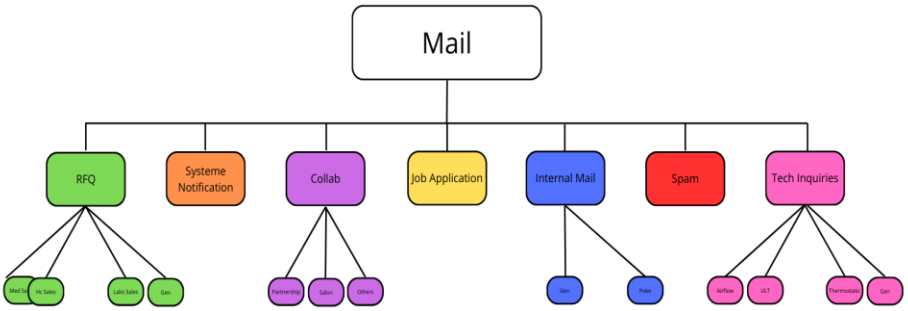


Figure 1 – Schéma de classification automatique des mails

La catégorie RFQ est mise en place pour les demandes de devis sur 3 sujets différents HC (Healthcare), Med (Médical), Labs (Laboratoires). Système Notification est présent pour notifier que le mail est automatique. Collab englobe les demandes de partenariat et les salons d'exposition ainsi que d'autre proposition éventuelle d'une autre entreprise. Job Application devra contenir les demandes d'emploi. Internal Mail peut contenir des mails interne à la boite. Spam a pour but de classé les spam afin de les éviter. Tech Inquiries devra classer les mails de demande de support technique en fonction de l'équipement sur lequel le support est demandé. (Airflow, ULT, Thermostatic ou General) ce sont les mots clé

2. Enjeux

L'enjeux majeur de ce projet et de réduire la charge de travail pour la personne qui s'occupe de la boite mail principal de l'entreprise et lui offrir une interface agréable et efficace. Le système d'archive est également un enjeu principal.

4. Réalisation

1. Phase de test sur Gmail avant intégration Outlook

Le but de réaliser une première connexion par Gmail est dans un premier temps de voir comment le mail est mis en forme lors du transfert via le protocole IMAP qui permet la récupération de mail sur une application Tiers.

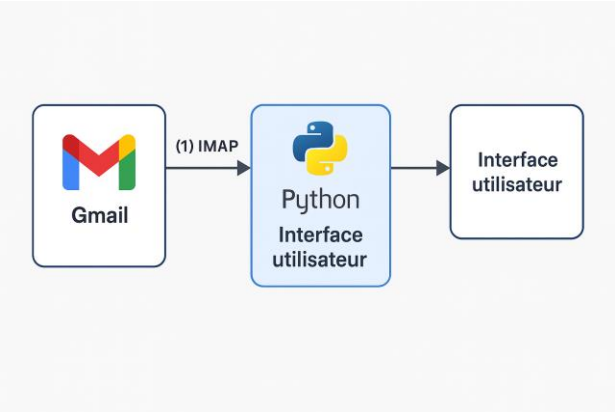


Figure 2 - Transfère de la donnée mail

Lors de ces premiers essais nous avons ainsi comprendre la mise en forme textuel des mails. Grâce à cela nous avons pu avancer sur le projet dans l'attente des droits pour la boite mail Outlook.

2. Étude et comparaison de plusieurs classifieurs

Modèle	Accuracy (%)	F1-score (%)	Temps d'entraînement	Avantages	Inconvénients
SVM	82.3	80.5	Moyen (~10s)	Bon équilibre précision/temps, robuste	Sensible au choix des paramètres, lent sur gros jeux
Random Forest	85.7	84.1	Rapide (~5s)	Facile à entraîner, gère bien les données bruitées	Moins performant sur mails courts ou ambigus
BERT	91.2	89.9	Long (~2 min)	Excellente compréhension du contexte, très précis	Lourd, nécessite plus de ressources, lent à prédire

Figure 2 - Tableau comparatif des classifieurs testés

Avant de choisir un modèle de classification pour notre application, nous avons testé trois approches différentes : SVM, Random Forest et BERT. Le tableau ci-dessus (Figure 2) résume leurs performances, le temps nécessaire pour les entraîner, ainsi que leurs points forts et leurs limites.

- SVM nous a offert un bon compromis entre précision et temps d'exécution. Il est plutôt robuste, mais il reste sensible au réglage des paramètres et peut devenir lent si la quantité de données devient trop importante.
- Random Forest s'est montré très rapide à entraîner et plutôt efficace pour des données bruitées. En revanche, il est moins performant sur les mails courts ou ambigus, ce qui arrive souvent dans des échanges professionnels.
- BERT, quant à lui, sort clairement du lot. Il affiche les meilleurs scores, que ce soit en accuracy ou en F1-score. C'est aussi le modèle qui comprend le mieux le contexte des messages. Mais il reste un peu plus lent.

Pourquoi avoir choisi BERT ?

Malgré son temps de traitement plus long, nous avons choisi BERT pour une raison simple : il fait un bien meilleur travail. Il comprend vraiment ce que le message veut dire, même quand c'est mal formulé, trop court ou ambigu. Et dans notre cas, où les mails peuvent prendre toutes sortes de formes, c'est un avantage considérable.

Alors oui, un mail met peut-être une ou deux minutes de plus à être classé avec BERT. Mais dans la réalité, ce petit décalage est totalement insignifiant. On ne cherche pas à répondre aux messages à la seconde près, mais à s'assurer qu'ils sont bien triés et dirigés vers la bonne catégorie. Et pour ça, mieux vaut un modèle qui prend son temps, mais qui ne se trompe pas.

En résumé, on a préféré miser sur la qualité plutôt que la vitesse. Et dans le cadre d'une application professionnelle, ce choix nous semble à la fois logique et pertinent.

3. Acquisition des mails sur Outlook

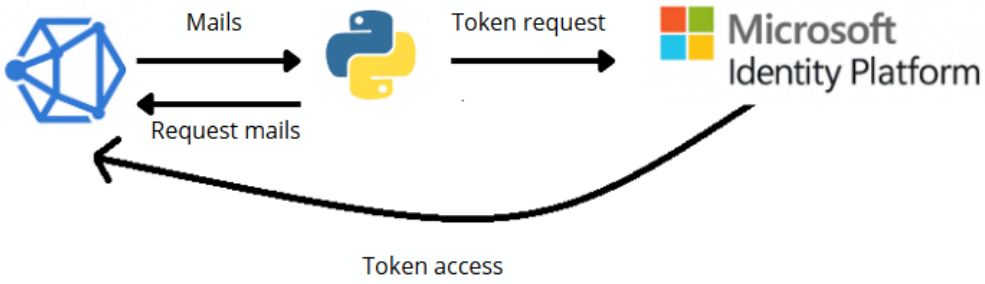


Figure 3 - Schéma d'acquisition de Mail protocol Outlook

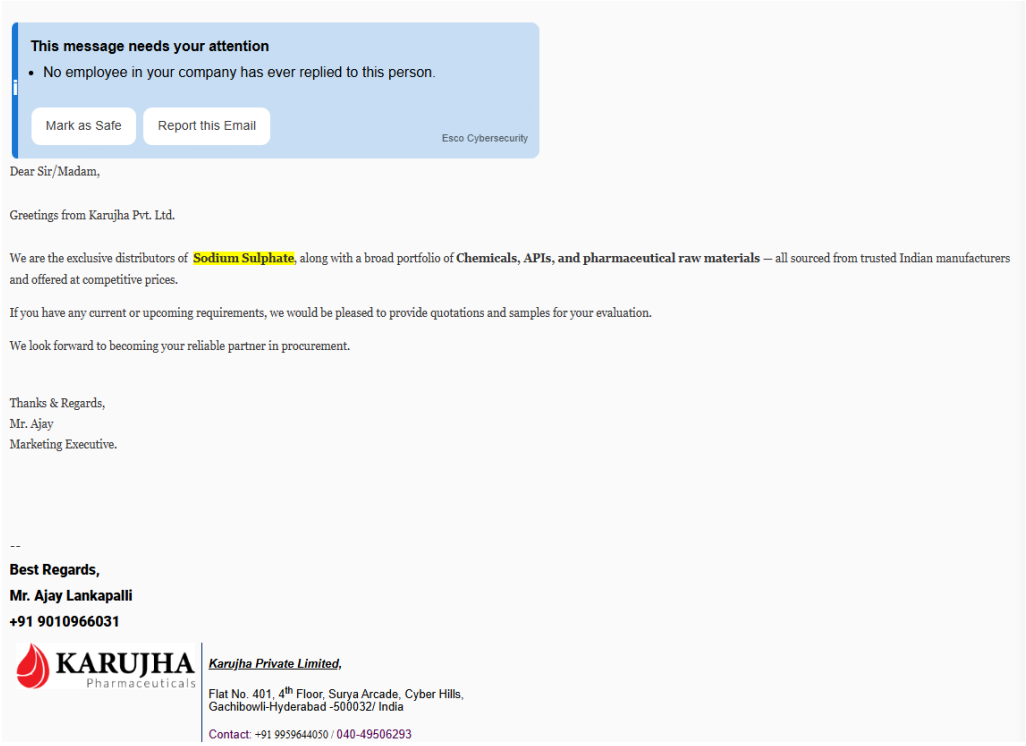
Le protocole pour récupérer les mails depuis Outlook est différent de celui de Gmail. Illustré dans la figure 3 ci-dessus il comporte plusieurs étapes pour accéder à une boite mail professionnel. Afin de maintenir l'accès sécurisé Outlook utilise un système de token temporaire qui impose donc l'utilisation de OAuth2.

Afin de mettre en place la récupération des mails on a donc plusieur étape :

- Python envoi une requête de lecture de mail a portal azure
- Portal azure utilise le token fournie avec l'identification platform de Microsoft
- Une fois le token activé Portal azure gere les envois de mail associé à la requête fait depuis le back end python

4. Préparation et traitement des données réelles

Avant toute phase de classification, une étape essentielle a consisté à nettoyer les contenus bruts des emails afin d'en extraire une version exploitable par les modèles NLP. Le contenu des mails, souvent au format HTML, a d'abord été converti en texte brut en supprimant les balises, les styles, les signatures automatiques et autres éléments visuels à l'aide de la bibliothèque *BeautifulSoup*. Ensuite, des expressions régulières ont été utilisées pour filtrer les éléments récurrents non pertinents, tels que les mentions légales, les disclaimers, les bannières de sécurité ou les traces de forwarding. Un effort particulier a été porté à la conservation du contenu sémantique réel de l'email (objet principal, requête, contexte) tout en éliminant le bruit. Cette version nettoyée a ensuite été utilisée comme entrée pour l'encodage par le modèle BERT. Ce prétraitement a grandement amélioré la clarté des données en entrée, réduisant ainsi le risque de mauvaise classification causée par des informations parasites.



This message needs your attention

- No employee in your company has ever replied to this person.

Mark as Safe | Report this Email

Esco Cybersecurity

Dear Sir/Madam,

Greetings from Karujha Pvt. Ltd.

We are the exclusive distributors of **Sodium Sulphate**, along with a broad portfolio of **Chemicals, APIs, and pharmaceutical raw materials** – all sourced from trusted Indian manufacturers and offered at competitive prices.

If you have any current or upcoming requirements, we would be pleased to provide quotations and samples for your evaluation.

We look forward to becoming your reliable partner in procurement.

Thanks & Regards,
Mr. Ajay
Marketing Executive.

--

Best Regards,
Mr. Ajay Lankapalli
+91 9010966031

KARUJHA Pharmaceuticals

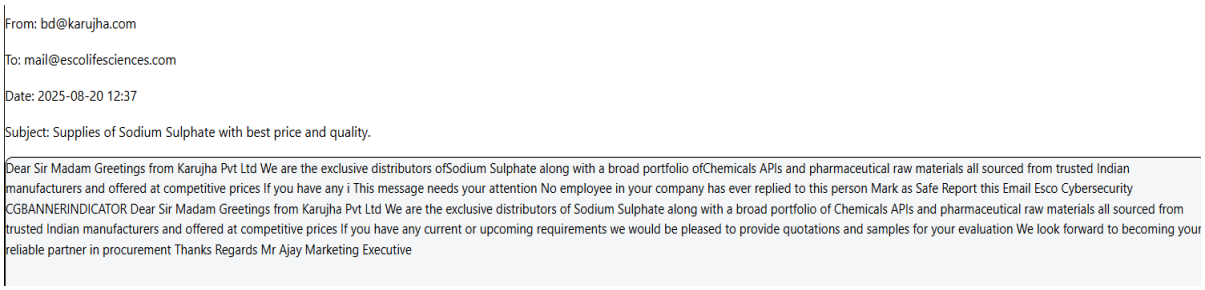
Karujha Private Limited,

Flat No. 401, 4th Floor, Surya Arcade, Cyber Hills,
Gachibowli-Hyderabad -500032/ India

Contact: +91 9959644050 / 040-49506293

Figure 4 – Exemple de mail récupéré et affiché sur la boite mail ESCO

La figure 4 représente un email brut tel qu'il est reçu dans la boîte Outlook, avec son contenu HTML, ses éléments visuels (encadré de sécurité, mises en forme, signatures, logos) et des messages automatiques ajoutés par Esco Cybersecurity. Ces éléments perturbent la compréhension réelle du message et biaisent le modèle de classification.



From: bd@karujha.com

To: mail@escolifesciences.com

Date: 2025-08-20 12:37

Subject: Supplies of Sodium Sulphate with best price and quality.

Dear Sir Madam Greetings from Karujha Pvt Ltd We are the exclusive distributors ofSodium Sulphate along with a broad portfolio ofChemicals APIs and pharmaceutical raw materials all sourced from trusted Indian manufacturers and offered at competitive prices If you have any i This message needs your attention No employee in your company has ever replied to this person Mark as Safe Report this Email Esco Cybersecurity CGBANNERINDICATOR Dear Sir Madam Greetings from Karujha Pvt Ltd We are the exclusive distributors of Sodium Sulphate along with a broad portfolio of Chemicals APIs and pharmaceutical raw materials all sourced from trusted Indian manufacturers and offered at competitive prices If you have any current or upcoming requirements we would be pleased to provide quotations and samples for your evaluation We look forward to becoming your reliable partner in procurement Thanks Regards Mr Ajay Marketing Executive

Figure 5 – Version du mail épuré aprés traitement

La figure 5 image montre la version nettoyée de ce même email, obtenue après suppression des balises HTML, des disclaimers, des blocs graphiques et des répétitions inutiles. Seul le contenu textuel principal, porteur d'intention (demande d'information ou devis), est conservé. Ce nettoyage permet d'obtenir une version claire, neutre et adaptée à l'analyse sémantique par le modèle BERT.

5. Implémentation du modèle BERT

Pour la classification des emails, nous avons utilisé BERT, un modèle d'intelligence artificielle conçu pour comprendre le langage. Chaque email est transformé en un vecteur numérique (*embedding*) qui résume son contenu de manière à ce qu'un ordinateur puisse en saisir le sens. Nous avons choisi la version all-MiniLM-L6-v2, plus légère et rapide, tout en conservant une bonne précision.

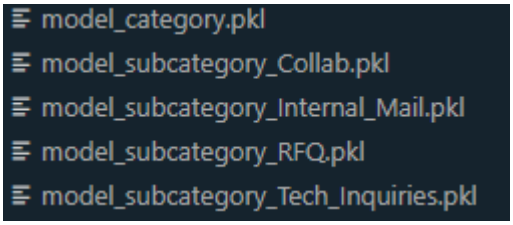


Figure 6 – Version du mail épuré aprés traitement

Ces vecteurs sont ensuite analysés par un classifieur supervisé (SGDClassifier de Scikit-learn) qui apprend à reconnaître les différentes catégories d'emails : RFQ, demandes techniques, candidatures, spam, etc. Pour les catégories plus complexes comme RFQ, un modèle supplémentaire permet de distinguer les sous-catégories (par exemple Lab Sales, HC Sales, Medical Sales). Chaque modèle entraîné est sauvegardé afin d'être réutilisé automatiquement sans avoir à repartir de zéro.

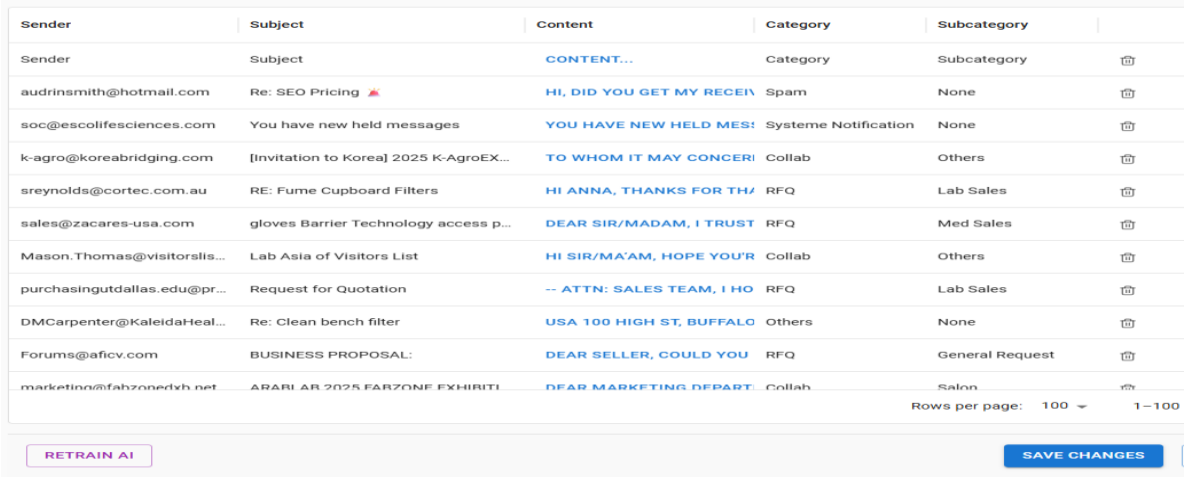


Figure 7 – Base de données du site avec le bouton Retrain AI

Enfin, l'interface inclut un bouton "Retrain AI". Il permet de réentraîner le modèle avec les corrections manuelles faites par les utilisateurs, afin que l'IA s'adapte progressivement aux nouveaux types d'emails. Ainsi, le système reste flexible, évolutif et de plus en plus précis au fil du temps.

6. Développement de l'interface utilisateur

Dans le cadre de ce projet, nous avons choisi de nous attarder principalement sur la version web de l'interface, car elle offre une plus grande accessibilité pour les utilisateurs d'ESCO Lifesciences, indépendamment de leur poste de travail. Cette version repose sur une architecture client-serveur avec FastAPI pour le backend et React pour le frontend.

FrontEnd :

Le frontend ne se limite pas à l'affichage des mails (expéditeur, objet, contenu, pièces jointes). Il offre plusieurs fonctionnalités avancées :

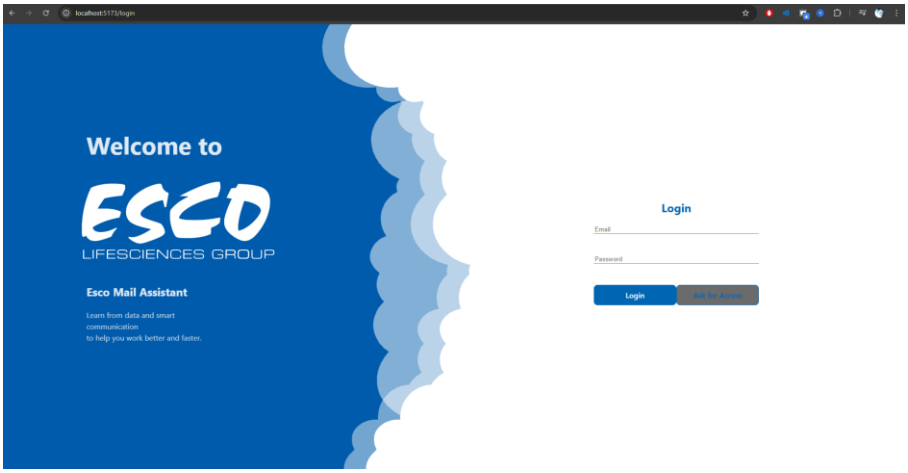


Figure 8 – Page de connexion

Une page de connexion sécurisée permet aux utilisateurs de s'authentifier avant d'accéder à l'interface, garantissant que seules les personnes autorisées peuvent consulter et classifier les emails.

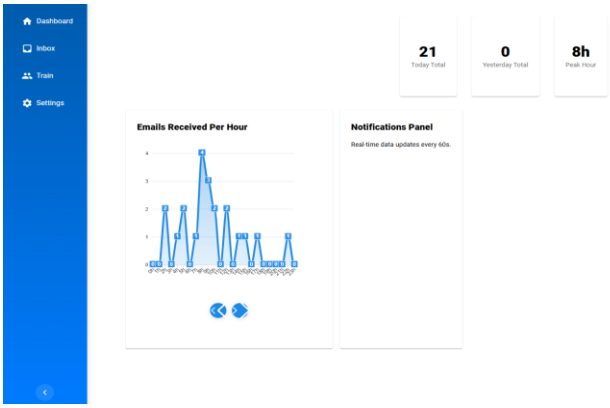


Figure 9 – Dashboard

Le dashboard centralise l'ensemble des informations et fonctionnalités : il affiche les emails traduits en anglais (si l'email contient une differente langue que l'anglais), classés, les statistiques de répartition par catégories, et donne accès aux actions principales comme la reclassification, l'ajout de catégories et le réentraînement de l'IA.

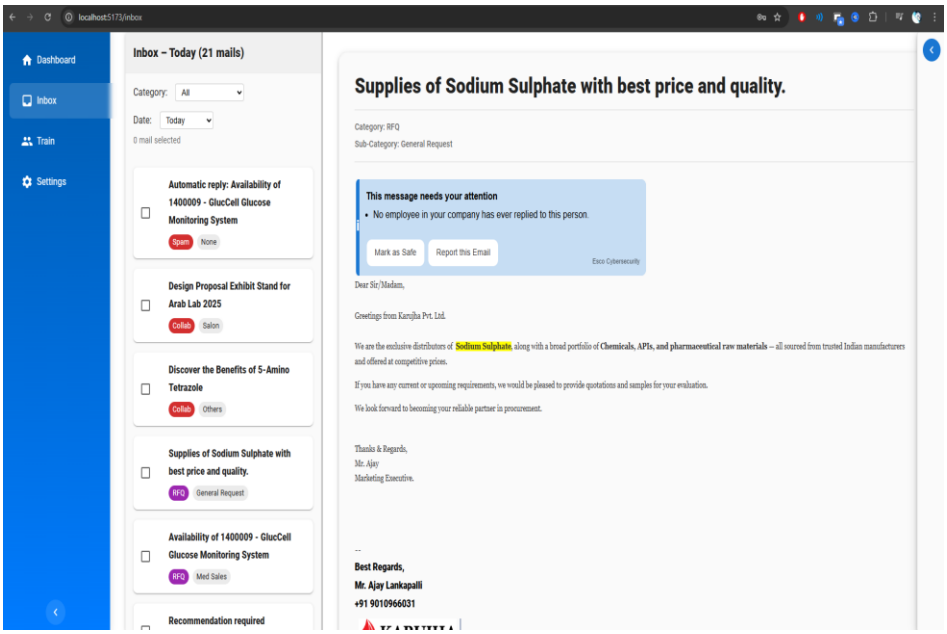


Figure 10 – Inbox

L'onglet Inbox constitue le cœur de l'application. Il présente la liste des emails reçus, affichés sous une forme lisible et organisée, avec pour chacun les informations principales : expéditeur, objet, date de réception, contenu du message et pièces jointes. Les emails sont automatiquement classés par l'IA, et une prédiction de la catégorie (RFQ, demande technique, candidature, spam, etc.) est indiquée directement dans l'interface. Lorsqu'il s'agit d'une catégorie complexe comme RFQ, la sous-catégorie prédite (ex. : Lab Sales, HC Sales, Medi cal Sales) apparaît également.

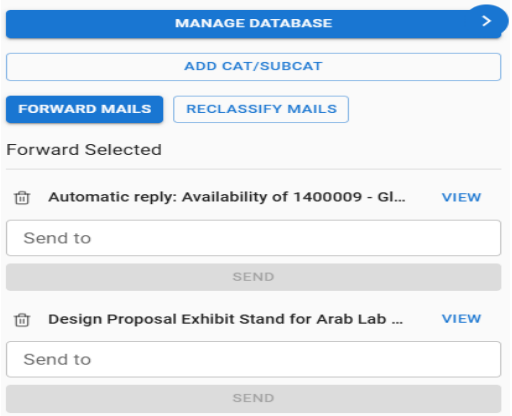


Figure 11 – Inbox

Envoi des emails vers la bonne personne ou service, une fois classés, les emails peuvent être redirigés automatiquement ou manuellement vers le bon destinataire.

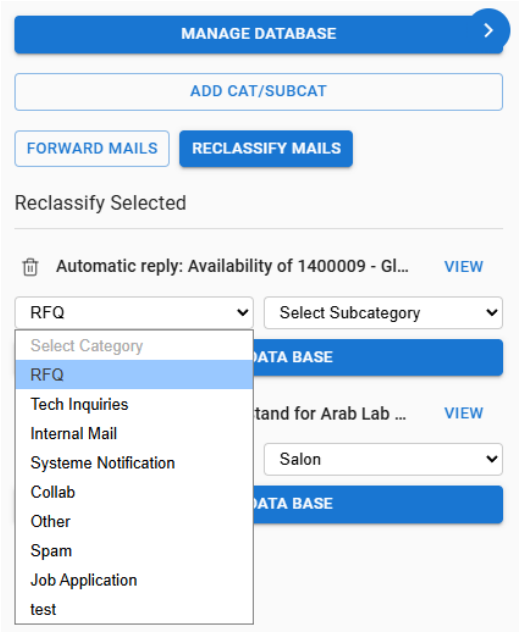


Figure 12 – Reclassificaiton manuelle

Reclassification manuelle : l'utilisateur peut corriger la catégorie proposée par l'IA grâce à un menu déroulant.

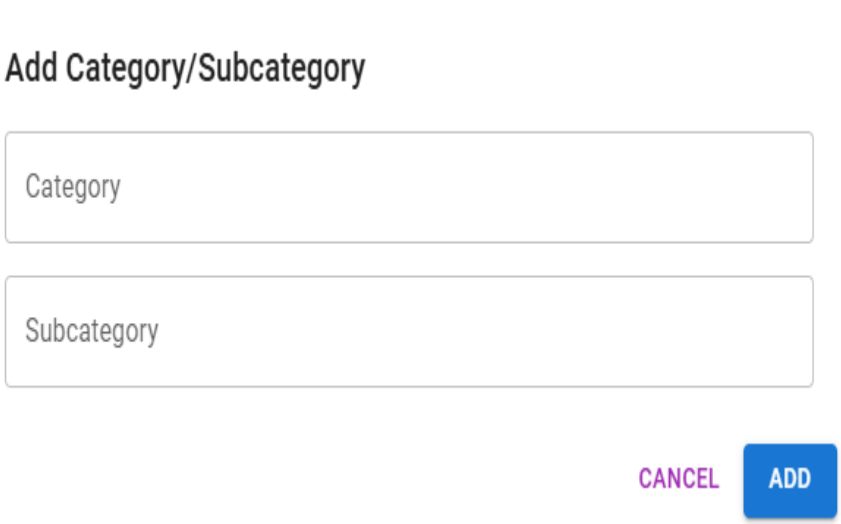


Figure 13 – Ajout de catégorie/sous-catégorie

Ajout de catégories et sous-catégories : le système est évolutif, permettant d'adapter la taxonomie à de nouveaux besoins.

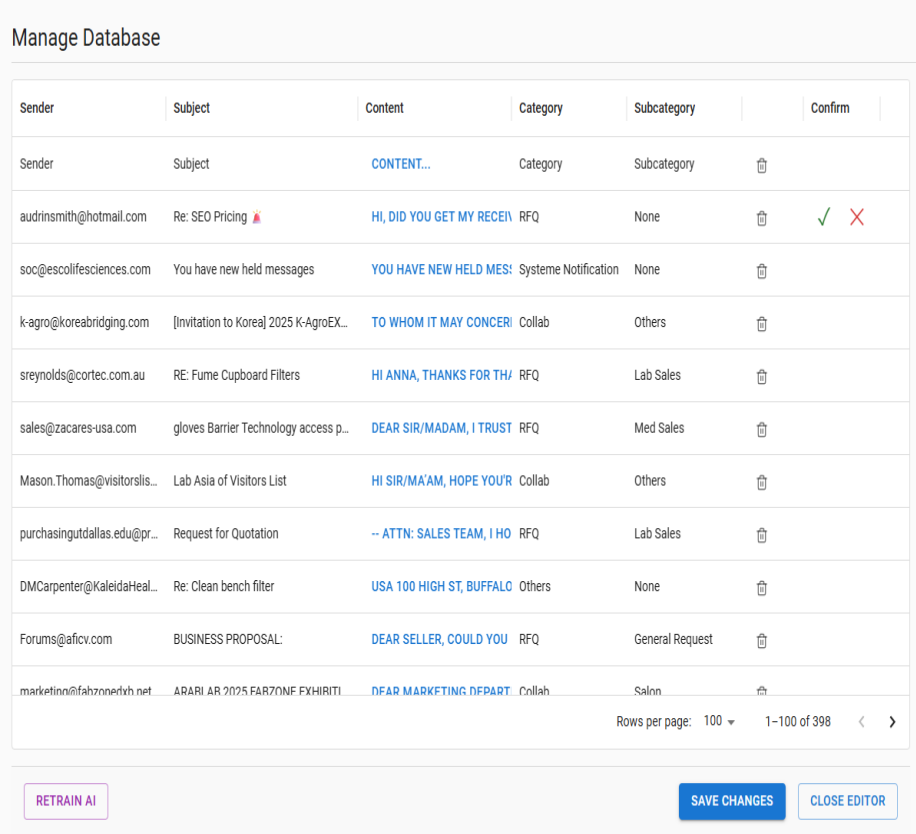


Figure 14 – Gestion de la base de donnée

Gestion de la base de données : toutes les corrections et ajouts sont enregistrés dans un fichier CSV ou une base de données, servant ensuite d'exemples pour améliorer le modèle. Réentraînement dynamique (Retrain AI) : via un bouton dédié, les utilisateurs peuvent lancer un réentraînement du modèle directement depuis l'interface, en intégrant les nouvelles corrections.

Ainsi, le frontend React devient un véritable tableau de bord intelligent : non seulement il permet de visualiser et classer les emails, mais il offre aussi la possibilité d'adapter le système en continu aux besoins de l'entreprise, de gérer la base d'apprentissage, et d'assurer la communication fluide entre l'IA et les utilisateurs humains.

BackEnd :

Le backend (FastAPI) est chargé de la logique métier : il communique avec Microsoft Graph API pour récupérer les emails, applique les étapes de nettoyage et de traduction, puis interroge les modèles de classification sauvegardés au format .pkl. Les résultats (catégorie et sous-catégorie) sont ensuite renvoyés sous forme de réponses JSON. FastAPI offre également une API REST bien structurée, permettant de gérer les requêtes des utilisateurs (par exemple, afficher les emails des dernières 24h, lancer une classification, ou déclencher un réentraînement).

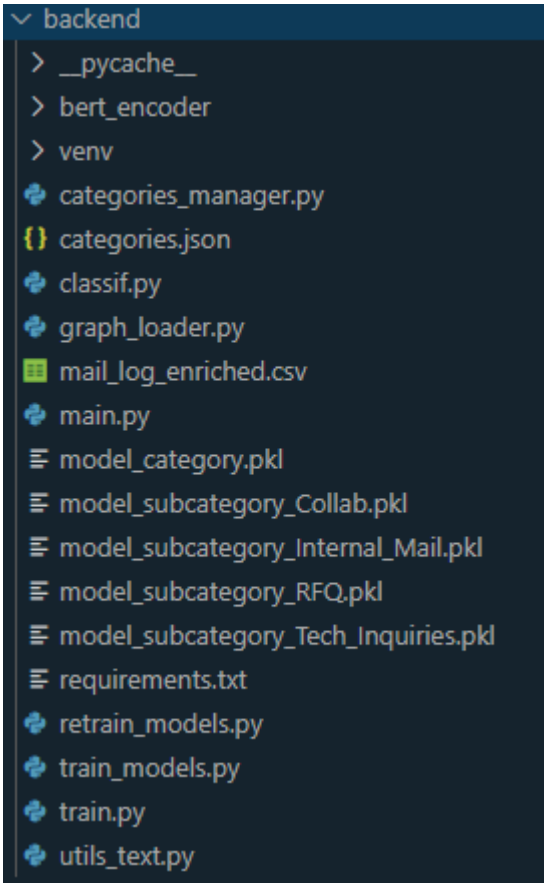


Figure 15 – Architecture du Backend

Fichiers	Rôle
main.py	Point d'entrée FastAPI : expose les endpoints (emails, classification, retrain).
classif.py	Logique de classification : email nettoyé → embedding → modèle catégorie/sous-catégorie.
utils_text.py	Nettoyage du texte (HTML → brut, suppression disclaimers, normalisation).
categories_manager.py	Gestion des catégories/sous-catégories (lecture/écriture categories.json).
categories.json	Fichier de configuration listant les catégories et sous-catégories utilisées.
model_category.pkl	Modèle principal entraîné pour prédire la catégorie globale d'un email.
model_subcategory_*.pkl	Modèles spécialisés pour affiner la prédiction dans une catégorie (RFQ, Tech Inquiries, etc.).
train.py	Script d'entraînement simple : nettoie, encode et entraîne un modèle.
train_models.py	Entraînement complet avec validation et sauvegarde des modèles.
retrain_models.py	Réentraînement déclenché par l'interface utilisateur (bouton "Retrain AI").
mail_log_enriched.csv	Jeu de données enrichi : emails avec prédictions/corrections pour l'apprentissage.
graph_loader.py	(Optionnel) Chargement d'un graphe métier pour enrichir les features (termes techniques, produits).
requirements.txt	Liste des dépendances Python (FastAPI, scikit-learn, transformers, etc.).

L'architecture du Frontend du projet peut être retrouvée en annexe

Conclusion

Ce projet a permis de concevoir et de mettre en place une solution complète de **classification automatique des emails** au sein d'ESCO Lifesciences. En combinant le nettoyage des données, l'utilisation du modèle **BERT** pour représenter le contenu des emails et l'entraînement de classifieurs supervisés, l'application atteint un haut niveau de précision tout en restant rapide et adaptable.

L'intégration dans une **interface web ergonomique** rend la solution accessible à tous les utilisateurs : visualisation des emails, correction des prédictions, ajout de catégories, gestion de la base d'apprentissage et réentraînement dynamique de l'IA. Cette interaction continue entre l'humain et la machine garantit un système évolutif, capable de s'améliorer au fil du temps.

Au-delà des gains immédiats en **efficacité et fiabilité**, ce travail ouvre la voie à de futures évolutions : détection automatique des priorités, synthèse intelligente des messages, intégration à d'autres outils collaboratifs ou encore extension à de nouveaux services internes. Ce projet constitue ainsi une étape importante vers une **gestion intelligente et proactive de la communication électronique** au sein de l'entreprise.



Merci à Esco et l'Université des Sciences de Montpellier

Bibliographie / Sitographie

- **Sentence-Transformers** : https://www.sbert.net/
- **Scikit-learn (SGDClassifier, pipelines de ML)** : https://scikit-learn.org/stable/
- **FastAPI (framework backend)** : https://fastapi.tiangolo.com/
- **React (framework frontend) :** https://react.dev/
- **Microsoft Graph API (accès aux emails Outlook)** : https://learn.microsoft.com/en-us/graph/overview
- **BeautifulSoup (nettoyage HTML)** : https://www.crummy.com/software/BeautifulSoup/bs4/doc/
- **Google Cloud Translation API** (intégration de la traduction automatique dans le pipeline de traitement des emails) : https://cloud.google.com/translate/docs
- **Python 3 Documentation officielle** : https://docs.python.org/3/
- **JSON en Python** : https://docs.python.org/3/library/json.html

Annexes

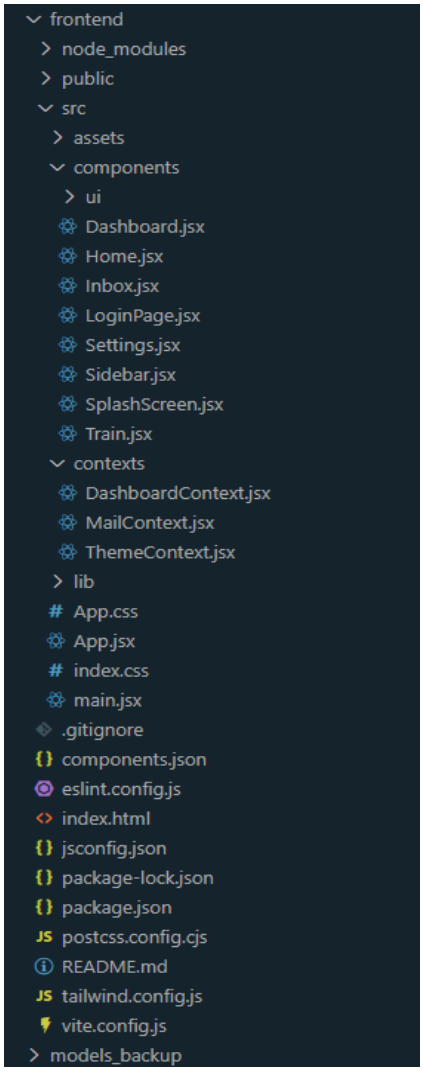


Figure 16 – Architecture du Frontend

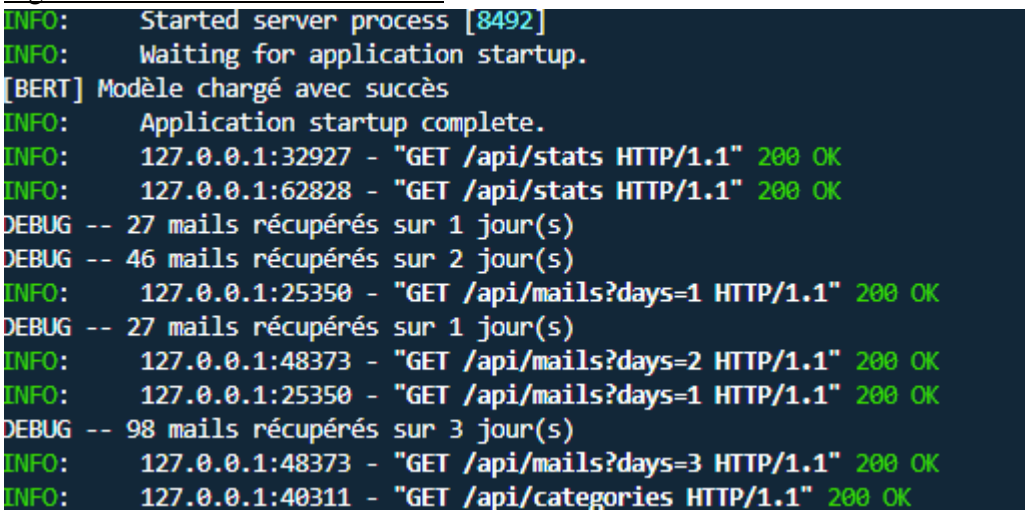


Figure 17 – Console de logs